

2026년도 머신러닝 프로젝트

AI 개발 수행내역서

과 제 명	KBO FA 선수 연봉 예측 AI 서비스 개발 (StoveLens AI)
담 당 자	박지수
제 출 일	2026년 6월 22일

사업과제 : KBO FA 선수 연봉 예측 AI 서비스 (StoveLens AI)

수행내용

1. 개요 및 현황

1.1 프로젝트 개요

KBO(한국야구위원회) 리그에서는 매년 10월 이후 스토브리그(Stove League)가 시작되며, FA(자유계약선수) 자격을 취득한 선수들의 연봉 협상이 진행된다. 그러나 구단 프런트, 에이전트, 팬 미디어 모두 '이 선수의 적정 연봉이 얼마인가?'라는 질문에 객관적인 데이터 기반 근거를 갖추기 어려운 실정이다.

본 프로젝트는 2015~2026년간의 KBO 선수 시즌 스탯과 FA 계약 실적 데이터(140건)를 수집·가공하여, 머신러닝 회귀 모델로 FA 선수의 예상 연봉을 예측하는 웹 서비스 'StoveLens AI'를 개발하였다. 선수 이름만 입력하면 AI가 연봉을 예측하고 구단별 적정 제시가까지 산출하는 Streamlit 기반 서비스로 구현하였다.

구분	내용
프로젝트명	StoveLens AI — KBO FA 선수 연봉 예측 서비스
예측 대상	FA 자격 취득 선수의 연평균 계약금 (annual_avg_salary, 단위: 억 원)
모델 구분	타자 예측 모델 / 투수 예측 모델 (독립 2모델)
학습 데이터	2018~2026년 FA 계약 실적 140건 + 2015~2026년 선수 시즌 스탯
적용 알고리즘	선형회귀, 랜덤포레스트, XGBoost (비교 실험)
서비스 형태	Streamlit 웹 앱 (로컬 / ngrok / Streamlit Cloud 배포)
평가 지표	R^2 , MSE, RMSE, MAE

1.2 추진배경 및 목적

- KBO FA 시장 규모 증가 및 데이터 기반 평가 필요성: FA(자유계약선수) 제도는 KBO 리그에서 고졸 10년, 대졸 9년 프로 경력을 충족한 선수가 소속 구단의 동의 없이 타 구단과 자유롭게 협상할 수 있는 제도이다. 최근 10년간 FA 시장 연평균 계약금이 꾸준히 상승하였으나, 선수 가치 평가는 여전히 주관적 판단에 의존하는 경우가 많다.

- 해외 리그 대비 KBO의 데이터 분석 체계 부재: MLB·NPB 등 해외 리그에서는 이미 세이버메트릭스(Sabermetrics) 기반 정량 평가 모델이 구단 운영의 핵심 수단으로 자리잡았으나, KBO에서는 이러한 분석 체계가 대중화되어 있지 않아 FA 협상의 투명성과 효율성이 낮은 실정이다.
- 활용 가능 대상 및 사회적 가치: 구단 프런트, 선수 에이전트, 야구 팬, 스포츠 미디어 등 다양한 이해관계자가 '이 선수의 시장 가치가 얼마인가'를 객관적으로 파악하고 싶은 모든 사용자를 대상으로 하며, KBO FA 시장 투명성 제고에 기여한다.
- 목적: 2015~2026년 KBO 선수 시즌 스탯 데이터와 FA 계약 실적 140건을 수집·가공하여 머신러닝 회귀 모델을 학습하고, 선수 이름 검색만으로 예상 연봉과 구단별 적정 제시가를 즉시 확인할 수 있는 Streamlit 기반 웹 서비스로 구현한다.

1.3 과제 범위

과제 구분	내용
AI 예측 모델	· 2015~2026년 KBO FA 선수 시즌 스탯 데이터 수집 및 데이터셋 구축 · 데이터 전처리, 피처 엔지니어링 (3년 평균·합계 파생변수 생성) · 탐색적 데이터 분석 (EDA) — 연봉 분포, 상관관계, 이상치 확인 · 타자/투수 분리 모델 선정 및 학습 (선형회귀, 랜덤포레스트, XGBoost) · R^2 , RMSE, MAE 등 평가지표를 활용한 모델 성능 평가 · Feature Importance 분석을 통한 연봉 결정 요인 도출 · 최종 모델 저장 (joblib .pkl 파일)
서비스 구현	· Streamlit 기반 웹 서비스 (StoveLens AI) 구현 · 선수 이름 검색 → 모드 A(FA 완료)/모드 B(미래 FA 예정) 자동 분기 · 예측 연봉 vs 실제 계약 비교 시각화 · 구단별 적정 제시가 산출 (10개 구단 × 보정계수 적용) · 선수 프로필 사진 자동 로딩, 핵심 스탯 시각화 · Streamlit Cloud 또는 ngrok을 통한 웹 배포 및 시연

1.4 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- 네이버 스포츠 API를 통해 2015~2026년 KBO 전 선수 시즌 스탯을 정형 데이터로 수집 가능하며, 수집 및 관리가 용이함

- FA 계약 실적(계약금·기간·포지션 등)은 공개 보도 자료 및 구단 공시를 통해 수집 가능하며, 예측 타겟(Y값)으로 활용 가능한 수치형 데이터가 명확히 존재함
- WAR, OPS, ERA, WHIP 등 종속변수(연봉)에 영향을 미치는 다양한 독립변수(피처)가 스탯 데이터에 포함되어 있어 모델 학습의 유용성이 높음

○ 예측모델 개발 효율성

- 예측 타겟이 연속형 수치(연평균 계약금, 억 원)로 명확하여 회귀(Regression) 문제로 정의하기 용이함
- 타자·투수 2개 모델로 분리하여 포지션 특성에 맞는 피처셋을 구성함으로써, 단일 모델 대비 예측 정확도와 해석력을 동시에 향상 가능
- 수업에서 학습한 선형회귀, 랜덤포레스트, XGBoost 등 주요 알고리즘을 모두 실험·비교할 수 있는 구조로 교육적 활용성이 높음


○ 서비스 활용성 및 사회적 가치

- FA 협상 시즌(스토브리그)마다 구단 프런트, 선수 에이전트, 야구 팬 등 다양한 이해관계자가 실제로 필요로 하는 정보를 제공할 수 있어 실용 가치가 높음
- Streamlit 웹 서비스로 구현하여 비개발자도 선수 이름 검색만으로 즉시 예측 결과를 확인할 가능하며, 향후 구단 연봉 협상 보조 도구로 확장 가능함

2) AI 예측 분석모델 적용 대상

기능 구분	수집 데이터	예측모델 인자 (독립변수)	AI 예측 분석 대상
타자 연봉 예측	· 2015~2026 KBO 타자 시즌 스탯 (타율 · OPS · WAR · 홈런 · 타점 · 도루 등) · FA 계약 실적 (2018~2026, 80건)	· war_3yr_sum, ops_3yr_avg · woba_3yr_avg, hr_3yr_avg · rbi_3yr_avg, games_3yr_avg · ops_last_year, war_last_year · age_at_fa, fa_year 등	· FA 선수 연평균 계약금 예측 (억 원) · 구단별 적정 제시가 · 예측 vs 실제 비교 (고평가/저평가 판별)
투수 연봉 예측	· 2015~2026 KBO 투수 시즌 스탯 (ERA · WHIP · WAR · 이닝 세이브 · 홀드 등) · FA 계약 실적 (2018~2026, 43건)	· war_3yr_sum, innings_3yr_avg · era_3yr_avg, whip_3yr_avg · hold_3yr_avg, save_3yr_avg · pitcher_role (SP/SU/CL) · age_at_fa, fa_year 등	· 투수 FA 연평균 계약금 예측 (억 원) · 역할별(선발/셋업/마무리) 연봉 기준 분석 · 구단별 적정 제시가

3) AI 분석모델 구축 프로세스



단계	주요 활동	산출물
DATA IMPORTING	· 네이버 스포츠 API 크롤링 (2015~2026) · FA 계약 실적 140건 수동 수집 · player_name + fa_year 기준 병합	naver_hitter/pitcher_raw.csv fa_contracts_v3.csv
데이터 전처리	· 데이터 누수 컬럼 제거 (total_contract_amount 등) · pitcherInning 문자열 파싱 (_parse_inning) · FA 직전 3년 스탯 평균·합계 생성 · 결측치 → 3년 평균 대체	hitter_training_v4.csv pitcher_training_v4.csv
모델링	· 선형회귀 / 랜덤포레스트 / XGBoost 비교 · 타자·투수 독립 모델 학습 · pitcher_role 원 핫인코딩 적용	hitter_model.pkl pitcher_model.pkl
예측	· annual_avg_salary 예측 (억 원) · 실제 계약금과 비교 · 구단별 보정계수 적용 → 제시가 산출	예측값 + 구단별 제시가
USER INSIGHT	· Streamlit 웹 서비스 화면 제공 · 선수 프로필·비교 차트·핵심 스탯 표시 · 구단별 제시가 막대 차트	StoveLens AI 웹 서비스

2. 데이터 수집

2.1 데이터 수집 개요

본 프로젝트에서 사용한 데이터는 크게 두 종류이다. ①FA 계약 실적 데이터(Y값, 정답 레이블)와 ②선수 시즌 스탯 데이터(X값, 피쳐)이다. 두 데이터를 선수명 + FA 연도 기준으로 병합하여 최종 학습 데이터셋을 구성하였다.

2.2 FA 계약 데이터 수집 (fa_contracts_v3.csv)

2018년부터 2026년까지 KBO FA 계약 사례 140건을 수동으로 조사·정리하였다. 각 선수의 계약 연도, 나이, 포지션, 계약 기간, 총액, 연평균 계약금을 포함한다.

컬럼명	타입	설명	예시
player_name	str	선수 이름	김현수
fa_year	int	FA 계약 연도	2018
age_at_fa	int	FA 당시 만 나이	30
position	str	포지션 코드 (OF/P/C/1B/SS/2B/3B/IF)	OF
contract_years	int	계약 기간 (년) ← 누수 컬럼, 모델 제외	4
total_contract_amount	float	총 계약금 (억 원) ← 누수 컬럼, 모델 제외	115.0
annual_avg_salary	float	연평균 계약금 ← 예측 타겟(Y)	28.75
team	str	계약 구단	LG
birth_year	int	생년 (나이 검증용)	1988

■ 연도별·포지션별 수집 현황

FA 연도	2018	2019	2020	2021	2022	2023	2024	2025	2026	합계
계약 건수	19	14	18	15	14	18	14	16	12	140
평균 연봉	9.67	10.24	7.11	8.72	13.81	9.26	7.28	9.54	12.76	-

FA 연도	2018	2019	2020	2021	2022	2023	2024	2025	2026	합계
(억)										

포지션	투수(P)	외야수(OF)	포수(C)	1루수(1B)	유격수(SS)	내야수(IF)	3루수(3B)	2루수(2B)	합계
건수	47	32	16	10	10	9	8	8	140

2.3 선수 시즌 스탯 수집 (2015~2026)

네이버 스포츠 내부 API를 활용하여 2015년부터 2026년까지 KBO 정규 시즌 타자·투수 스탯을 수집하였다. 2018년 FA 선수의 경우 FA 직전 3년치(2015~2017) 데이터가 필요하므로 2015년부터 수집을 시작하였다.

구분	API 엔드포인트	수집 방법	주요 컬럼
타자	GET .../kbo/seasons/{year}/players ?playerType=HITTER &sortField=hitterWar	연도별 전수 수집 (pageSize=100 반복)	타율·출루율·장타율·OPS·WAR·홈런·타점·도루 등 20+
투수	동일 API ?playerType=PITCHER	7개 sortField 반복 수집 후 dedup (마무리·계투 누락 방지)	ERA·WHIP·WAR·이닝·세이브·홀드·삼진 등 15+

△ 투수 데이터 수집 시 pitcherWar 단일 기준으로 정렬하면 등판 경기가 적은 마무리·셋업맨이 누락된다. → pitcherWar / pitcherSave / pitcherHold / pitcherKk / pitcherWin / pitcherEra / pitcherWhip 등 7개 기준으로 반복 수집 후 playerName+year 키 기준 중복 제거 (crawl_pitcher_all.py)

3. 데이터 전처리

3.1 데이터 누수(Data Leakage) 발견 및 제거

데이터 누수(Data Leakage)란 모델이 실제 예측 시점에는 알 수 없는 정보가 학습 피처에 포함되어, 모델 성능이 비현실적으로 과대 평가되는 현상이다. 초기 학습(v1) 시 R^2 값이 비정상적으로 높게 나타나 원인을 분석한 결과, 아래 컬럼들이 정답(Y값)과 직접적인 관계를 가진다는 것을 발견하였다.

제외 컬럼	누수 이유	영향
annual_avg_salary	예측 타깃 자체 (Y값 그 자체)	모델에 답을 직접 넣는 것
total_contract_amount	연봉 × 계약기간 = 총액. 타깃을 역산 가능	$R^2 \approx 1.00$ 인위적 과적합
contract_years	계약 기간도 연봉 협상 결과물. FA 시점에 미확정	정보 누수
player_name	선수 이름은 ID. 모델이 이름으로 기억하면 일반화 불가	과적합
position	문자열 그대로 입력 시 LabelEncoding 오용 가능	별도 피처 설계 필요
team	소속팀보다 구단별 보정계수가 더 의미 있음 (2차 보정에서 활용)	일반화 방해

△ v1 모델 $R^2 \approx 0.99 \rightarrow$ 누수 제거 후 v2 타자 $R^2 = 0.388$ / 투수 $R^2 = 0.756$. 이 수치가 현실적인 예측력이다.


```
import pandas as pd
import os

os.chdir('/Users/tina/Desktop/SalaryCast_AI') # 프로젝트 루트로 이동

df = pd.read_csv('data/naver_hitter_2015_2026_raw_all.csv', encoding='utf-8-sig')
print(df.shape)
df.head()
```

✓ 0.0s Python

(1390, 50)

	ranking	playerId	playerName	playerImageUrl	weight	height	backNumber	isRetire	isPlayer	osId	...	hitter
0	NaN	61700	강경학	https://sports-phinf.pstatic.net/player/kbo/de...	72	180	14	N	Y	188739.0	...	
1	NaN	74215	윤석민	https://sports-phinf.pstatic.net/player/kbo/de...	88	180	5	Y	Y	124115.0	...	
2	NaN	75334	오재일	https://sports-phinf.pstatic.net/player/kbo/de...	95	187	36	Y	Y	124087.0	...	
3	NaN	79365	박동원	https://sports-phinf.pstatic.net/player/kbo/de...	92	178	27	N	Y	165271.0	...	
4	NaN	79705	김희성	https://sports-phinf.pstatic.net/player/kbo/de...	92	190	24	Y	Y	162572.0	...	

3.2 이닝 데이터 파싱 (pitcherInning 문자열 처리)

수집된 투수 데이터의 pitcherInning 컬럼이 '184 1/3', '72 2/3' 과 같이 정수+분수 혼합 문자열(string)로 저장되어 있었다. 이를 모르고 직접 .mean() 등 수치 연산을 적용하자 다음 오류가 발생하였다.

```
# 발생 오류 TypeError: Cannot perform reduction 'mean' with string dtype # 원인 >>
df['pitcherInning'].dtype # → object (문자열) >> df['pitcherInning'].head() # →
'184 1/3', '72 2/3', '150', ...
```

■ 해결: _parse_inning() 파싱 함수 작성

```
def _parse_inning(val) -> float: """'184 1/3' 형식 이닝 문자열 → float 변환"""
if pd.isna(val): return 0.0
s = str(val).strip()
if " " in s:
    whole, frac = s.split(" ", 1)
    n, d = frac.split("/")
    return float(whole) + float(n)/float(d)
try: return float(s)
except: return 0.0
# 적용: stat_df 로드 후 즉시 전처리 stat_df["pitcherInning"] =
stat_df["pitcherInning"].apply(_parse_inning)
```

✓ 적용 결과: '184 1/3' → 184.333, '72 2/3' → 72.667 정상 변환 확인

3.3 결측치 처리

FA 계약 직전 시즌 스탯(last_year 계열)은 부상, 군 복무, 시즌 도중 방출 등으로 결측이 발생할 수 있다. 이를 3년 평균값으로 대체하여 학습 데이터의 완전성을 확보하였다.

구분	결측 발생 컬럼	처리 방법	처리 결과
타자	war_last_year, ops_last_year,	3년 평균값으로 대체	결측치 0건 달성

구분	결측 발생 컬럼	처리 방법	처리 결과
	wrc_plus_last_year		
투수	era_last_year, whip_last_year	3년 평균값으로 대체	결측치 0건 달성

```
# 결측치 대체 로직 (model_train_v2.ipynb) for col_last, col_avg in
[ ('war_last_year', 'war_3yr_avg'), ('ops_last_year', 'ops_3yr_avg'),
('era_last_year', 'era_3yr_avg'), ('whip_last_year', 'whip_3yr_avg'), ]:
df[col_last] = df[col_last].fillna(df[col_avg]) print('남은 결측치:',
df.isnull().sum().sum()) # → 0
```

=== 결측치 처리 전 ===

```
ranking          1192
playerId          0
playerName        0
playerImageUrl    0
weight            0
height            0
backNumber        0
isRetire          0
isPlayer          0
osId              20
profile           25
enable            0
teamId            0
teamName          0
teamShortName     0
teamImageUrl      0
seasonId          0
year              0
upperCategoryId   0
categoryId        0
league            1390
division          1390
hitterHra         0
hitterRbi         0
...
sort_source       0
dtype: int64
```

전체 결측치 수: 6797

Output is truncated. View as a [scrollable element](#) or open in a [text editor](#). Adjust cell output [settings](#)...

```
=== 결측치 처리 후 ===
```

```

ranking          0
playerId         0
playerName       0
playerImageUrl   0
weight          0
height          0
backNumber       0
isRetire         0
isPlayer         0
osId            0
profile         0
enable          0
teamId          0
teamName        0
teamShortName    0
teamImageUrl     0
seasonId        0
year            0
upperCategoryId  0
categoryId       0
league          0
division        0
hitterHra       0
hitterRbi       0
...
sort_source      0
dtype: int64

```

```
전체 결측치 수: 0
```

Output is truncated. View as a [scrollable element](#) or open in a [text editor](#). Adjust cell output [settings](#)...

3.4 학습 데이터셋 생성 (피처 엔지니어링)

FA 계약 데이터(140건)를 기준으로, 각 선수의 FA 직전 3개년 시즌 스탯을 집계하여 평균(3yr_avg)과 합계(3yr_sum) 파생 피처를 생성하였다.

구분	파일명	샘플 수	피처 수	타깃 컬럼	train/test
타자 모델	hitter_training_v4.csv	80명	30개	annual_avg_salary	64 / 16 (80:20)
투수 모델	pitcher_training_v4.csv	43명	16개	annual_avg_salary	34 / 9 (80:20)

■ 타자 모델 주요 피처 (30개)

피처명	설명	비고
fa_year	FA 계약 연도	연봉 인플레이션 반영
age_at_fa	FA 당시 나이	나이 높을수록 계약 감소 경향
war_3yr_avg / war_3yr_sum	WAR 3년 평균 / 합계	팀 기여도 핵심 지표
ops_3yr_avg / ops_last_year	OPS 3년 평균 / 직전 시즌	타격 종합 능력
woba_3yr_avg	wOBA 가중 출루율 3년 평균	타격 결과 종류별 가중 지표
wrc_plus_3yr_avg / wrc_plus_last_year	조정 득점 생산력 3년평균 / 직전	리그·파크 보정 타격지표
hr_3yr_avg	홈런 3년 평균	장거리포 프리미엄
rbi_3yr_avg	타점 3년 평균	클러치 능력
obp_3yr_avg / slg_3yr_avg	출루율·장타율 3년 평균	OPS 구성 요소
sb_3yr_avg	도루 3년 평균	스피드 지표
games_3yr_avg	출전 경기수 3년 평균	내구성·신뢰도
그 외 19개	타율·득점·2루타·3루타·볼넷·삼진 등	세부 타격 지표

■ 투수 모델 주요 피처 (16개)

피처명	설명	비고
fa_year	FA 계약 연도	△ 중요도 1위 — 연봉 인플레이션
age_at_fa	FA 당시 나이	
war_3yr_avg / war_3yr_sum	WAR 3년 평균 / 합계	투수 종합 기여도
era_3yr_avg / era_last_year	방어율 3년 평균 / 직전 시즌	낮을수록 우수

피처명	설명	비고
whip_3yr_avg / whip_last_year	WHIP 3년 평균 / 직전 시즌	이닝당 출루 허용
innings_3yr_avg	소화 이닝 3년 평균	선발 내구성 핵심
save_3yr_avg / hold_3yr_avg	세이브·홀드 3년 평균	역할 구분 지표
win_3yr_avg / lose_3yr_avg	승·패 3년 평균	선발 성과
games_3yr_avg	등판 경기수 3년 평균	활동성
pitcher_role_SU / pitcher_role_CL	역할 원핫인코딩 (SP 기준)	pitcher_role 적용 후 추가

=== 타자 학습 데이터 ===
shape: (80, 36)

	fa_year	age_at_fa	games_3yr_avg	ab_3yr_avg	avg_3yr_avg	obp_3yr_avg	slg_3yr_avg	ops_3yr_avg	isop_3yr_avg
count	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000
mean	2021.325000	33.912500	122.233333	413.177083	0.289572	0.364560	0.439550	0.804110	0.149994
std	2.474042	3.194908	12.857397	77.526668	0.026050	0.026512	0.070207	0.088877	0.059626
min	2018.000000	26.000000	85.500000	136.000000	0.213687	0.297000	0.273667	0.592000	0.031000
25%	2019.000000	31.000000	115.333333	376.000000	0.269267	0.350375	0.385333	0.745833	0.104000
50%	2021.000000	34.000000	125.833333	416.416667	0.292248	0.368833	0.451500	0.806667	0.151000
75%	2023.000000	36.000000	130.250000	468.833333	0.312181	0.384375	0.481167	0.859875	0.194167
max	2026.000000	43.000000	141.000000	532.000000	0.331287	0.420000	0.603667	1.003000	0.321000

8 rows x 33 columns

=== 투수 학습 데이터 ===
shape: (43, 22)

	fa_year	age_at_fa	contract_years	total_contract_amount	annual_avg_salary	games_3yr_avg	innings_3yr_avg	era_3yr
count	43.000000	43.000000	43.000000	43.000000	43.000000	43.000000	43.000000	43.000000
mean	2022.511628	34.209302	2.930233	23.500000	7.469302	44.364341	84.408269	4.520000
std	2.649098	4.223281	1.032688	19.059856	4.725240	16.112422	40.733526	1.500000
min	2018.000000	26.000000	1.000000	1.200000	1.200000	18.500000	30.777778	2.560000
25%	2020.000000	31.000000	2.000000	9.150000	3.625000	28.500000	56.388889	3.820000
50%	2023.000000	33.000000	3.000000	16.000000	6.000000	43.666667	66.000000	4.310000
75%	2025.000000	37.500000	4.000000	37.000000	10.000000	59.333333	106.694444	4.960000
max	2026.000000	42.000000	4.000000	78.000000	19.500000	71.000000	169.166667	12.670000


4. 탐색적 데이터 분석 (EDA)

4.1 연봉 분포 분석

FA 계약 연봉(annual_avg_salary)의 분포를 분석하였다. 타자와 투수 모두 오른쪽 꼬리가 긴 분포(Right-skewed)를 보이며, 소수 스타 선수의 대형 계약이 평균을 끌어올리는 구조이다.

통계량	타자 (80명)	투수 (43명)	해석
평균 (Mean)	11.90억 원	7.47억 원	스타 선수 계약이 평균 끌어올림
중앙값 (Median)	10.25억 원	6.00억 원	실질 '보통' 선수 기준
표준편차 (Std)	6.91억 원	4.73억 원	편차 큼 → 예측 난이도 높음
최솟값 (Min)	0.55억 원	1.20억 원	은퇴 임박 선수
최댓값 (Max)	31.25억 원	19.50억 원	리그 최고 대우 선수
25% 분위수	6.92억 원	3.62억 원	
75% 분위수	16.06억 원	10.00억 원	


KBO FA 연봉 분포 (2015~2026)



4.2 연도별 FA 평균 연봉 추이

2018~2026년 FA 연도별 평균 계약 연봉을 분석하면 전반적인 상승 추세가 확인된다. 다만 2020년(코로나19 영향), 2024년에 일시 하락이 관찰되었다. 이러한 연봉 인플레이션 효과가 fa_year 피처가 모델에서 높은 중요도를 가지는 원인이다.

FA 연도	2018	2019	2020	2021	2022	2023	2024	2025	2026
FA 평균연봉 (억)	9.67	10.24	7.11	8.72	13.81	9.26	7.28	9.54	12.76




4.3 주요 피처와 연봉 간 상관관계 분석 (Heatmap)


연봉과 상관관계가 높은 피처를 분석한 결과, 타자는 WAR 합계(war_3yr_sum)·OPS·wOBA 순으로, 투수는 WAR·이닝(innings_3yr_avg)·WHIP 역수 순으로 상관관계가 강하게 나타났다.

- EDA 히스토그램, 히트맵 등 변수별 분포를 통해 정규분포 여부, 데이터 변환 필요성 및 변수 간 관계를 분석하였다.
- 연봉 예측 모델링을 위한 주요 대상 설정: 타자는 war_3yr_sum과 ops 계열 지표, 투수는 innings_3yr_avg와 era_3yr_avg를 핵심 피처로 선정하였다.
- 연봉에 영향을 미치는 요인 분석
 - 성적변수: war_3yr_sum, ops_3yr_avg, woba_3yr_avg, era_3yr_avg, innings_3yr_avg
 - 나이변수: age_at_fa (나이가 높을수록 계약 규모 감소 경향)
 - 역할변수: pitcher_role (SP 선발 / SU 셋업맨 / CL 마무리) — 동일 성적에서 역할에 따라 연봉 차이 존재

순위	타자 피처	상관계수(추정)	투수 피처	상관계수(추정)
1위	war_3yr_sum	0.55+	war_3yr_sum	0.65+
2위	ops_3yr_avg	0.50+	innings_3yr_avg	0.60+
3위	woba_3yr_avg	0.48+	era_3yr_avg (억)	0.55+

순위	타자 피쳐	상관계수(추정)	투수 피쳐	상관계수(추정)
4위	hr_3yr_avg	0.45+	whip_3yr_avg (역)	0.52+
5위	rbi_3yr_avg	0.43+	hold_3yr_avg	0.45+





5. 모델 정의 및 학습

5.1 문제 유형 및 알고리즘 선택

- 문제 유형: 예측 목표값(연봉)이 연속형 수치이므로 지도학습 회귀(Regression) 문제로 정의한다.
- 타자/투수 모델 분리: 타자와 투수는 역할·평가 지표가 근본적으로 다르므로 동일 모델로 학습 시 피처 의미가 혼재되어 성능이 저하된다. 독립적인 2개 모델로 설계하였다.
- 수업 커리큘럼 반영: 수업에서 학습한 선형회귀, 다항회귀, 랜덤포레스트, XGBoost를 모두 적용하여 성능을 비교하였다.

알고리즘	수업 노트북	선택 이유	역할
선형 회귀 (LinearRegression)	회귀 노트북 1	기준선(Baseline) 모델. 계수(coefficient)로 각 피처의 연봉 영향력 직관 해석 가능. 다중선형회귀 형태	Baseline
다항 회귀 (PolynomialFeatures)	회귀 노트북 1	나이(age_at_fa)의 비선형 효과 반영. 젊을수록 계약 기간이 더 길어지는 비선형 관계 포착. age_squared로 간접 적용	비교 모델
랜덤 포레스트 (RandomForestRegressor)	앙상블 노트북 1	다수 의사결정나무 앙상블로 과적합 억제. feature_importances_로 연봉 결정 요인 분석 가능	주요 모델 후보
XGBoost (XGBRegressor)	부스팅 노트북 2	경사하강법 기반 그래디언트 부스팅. 소규모 데이터에서 과적합 제어 우수. 자전거 수요 예측 예제 참고	최종 모델 후보

5.2 인코딩 처리 (pitcher_role 카테고리 변수)

투수 역할(pitcher_role: SP선발/SU셋업/CL마무리)은 문자열 범주형 변수이므로 모델 입력 전 수치 변환이 필요하다. 수업에서 배운 두 가지 방법을 모두 실험하였다.

■ 투수 역할 분류 규칙

```
def assign_role(row):
    if row['save_3yr_avg'] >= 10: return 'CL' # 마무리 (세이브 기준)
    if row['hold_3yr_avg'] >= 10: return 'SU' # 셋업맨 (홀드 기준)
```

```
return 'SP' # 선발 투수 pitcher_df['pitcher_role']
= pitcher_df.apply(assign_role, axis=1)
```

■ 인코딩 방법 비교

방법	코드	특징	채택
라벨 인코딩 (LabelEncoder)	le = LabelEncoder() df['role_enc'] = le.fit_transform(df['pitcher_role'])	SP=0/SU=1/CL=2 매핑. 빠르지만 숫자 크기에 의 미가 생기는 부작용 가능	비교용
원핫 인코딩 (pd.get_dummies)	df = pd.get_dummies(df, columns=['pitcher_role'], drop_first=True)	각 역할별 0/1 이진 컬럼 생성. 범주형 변수 처리의 표준 방법	채택 ☒

△ pitcher_role을 3개 모델(SP/SU/CL)로 분리하지 않고 단일 피처로 통합한 이유: KBO FA 투수 데이터는 연간 5~10명 수준. 3분할 시 서브셋이 너무 작아 모델이 패턴을 학습하지 못함. 역할별 중요 스탯(SP→이닝, SU→홀드, CL→세이브)을 피처로 포함하고 XGBoost가 자동 학습하도록 설계.

5.3 학습/테스트 데이터 분리 및 학습 코드

구분	전체	학습 (80%)	테스트 (20%)	random_state
타자	80명	64명	16명	42
투수	43명	34명	9명	42

```
from sklearn.model_selection import train_test_split from sklearn.linear_model
import LinearRegression from sklearn.ensemble import RandomForestRegressor from
sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error from
xgboost import XGBRegressor import numpy as np X = df[feature_cols] y =
df['annual_avg_salary'] X_train, X_test, y_train, y_test =
train_test_split(X, y, test_size=0.2, random_state=42) models =
{ 'LinearRegression': LinearRegression(), 'RandomForest':
RandomForestRegressor(n_estimators=100, random_state=42), 'XGBoost':
XGBRegressor(n_estimators=100, max_depth=4,
learning_rate=0.1, random_state=42), } for name, model in models.items():
model.fit(X_train, y_train) pred = model.predict(X_test) r2 =
r2_score(y_test, pred) mse = mean_squared_error(y_test, pred) rmse =
np.sqrt(mse) mae = mean_absolute_error(y_test, pred) print(f'{name}:
R²={r2:.3f} RMSE={rmse:.2f}억 MAE={mae:.2f}억')
```

[타자] 모델 평가 결과

```

선형회귀 (Linear Regression)  R²=0.325  RMSE=6.29억  MAE=4.80억
랜덤포레스트 (Random Forest)  R²=0.365  RMSE=6.10억  MAE=4.78억
XGBoost                      R²=0.330  RMSE=6.27억  MAE=4.48억
  
```

[투수] 모델 평가 결과

```

선형회귀 (Linear Regression)  R²=0.812  RMSE=2.89억  MAE=2.51억
랜덤포레스트 (Random Forest)  R²=0.604  RMSE=4.20억  MAE=3.58억
XGBoost                      R²=0.659  RMSE=3.89억  MAE=3.32억
  
```

=== 타자 결과표 ===

	R²	RMSE	MAE
모델			
선형회귀 (Linear Regression)	0.325	6.29	4.80
랜덤포레스트 (Random Forest)	0.365	6.10	4.78
XGBoost	0.330	6.27	4.48

=== 투수 결과표 ===

	R²	RMSE	MAE
모델			
선형회귀 (Linear Regression)	0.812	2.89	2.51
랜덤포레스트 (Random Forest)	0.604	4.20	3.58
XGBoost	0.659	3.89	3.32

5.4 모델 저장 (joblib)

```

import joblib # 모델 저장
joblib.dump(best_hitter_model,
'models/hitter_model.pkl')
joblib.dump(hitter_feature_cols,
'models/hitter_features.pkl')
joblib.dump(best_pitcher_model,
'models/pitcher_model.pkl')
joblib.dump(pitcher_feature_cols,
'models/pitcher_features.pkl')
# Streamlit 앱에서 로드
model = joblib.load('models/hitter_model.pkl')
feats = joblib.load('models/hitter_features.pkl')
pred = model.predict(player_df[feats])[0]
print(f'예측 연봉: {pred:.1f}억 원')
  
```

6. 모델 평가

6.1 평가 지표 정의

지표	수식	해석 기준	본 프로젝트 적용
R^2 (결정계수)	$1 - SS_{res}/SS_{tot}$	1에 가까울수록 좋음. 0.7 이상 → 실용 모델	연봉 변동성의 몇 %를 설명하는지
MSE (평균제곱오차)	$\Sigma(y-\hat{y})^2/n$	낮을수록 좋음. 단위: 억 ²	큰 오차에 민감 (이상값 영향)
RMSE (평균제곱근오차)	$\sqrt{MSE}$	연봉과 동일 단위(억). =5 → 평균 5억 오차	직관적 오차 해석
MAE (평균절대오차)	$\Sigma y-\hat{y} /n$	이상값 영향 적음. 낮을수록 좋음	'평균적으로 N억 빗나감'

6.2 타자 모델 성능 결과

모델	R^2	MSE	RMSE (억)	비고
선형 회귀 (Baseline)	0.384	36.07	6.01	다중선형회귀
랜덤 포레스트	0.388	35.86	5.99	n_estimators=100
XGBoost	측정 예정	—	—	향후 실험

해석: 타자 모델 R^2 0.388은 성적 지표만으로 연봉의 38.8%를 설명한다는 의미이다. 나머지 61.2%는 스타성(MVP/골든글러브/팬 인기도), 에이전트 협상력, 구단 예산 상황, 포지션 희소성 등 수치화가 어려운 요인에 기인한다. 향후 MVP 수상 횟수, 골든글러브, 국가대표 경력 등 스타성 변수를 추가하면 R^2 향상이 기대된다.

6.3 투수 모델 성능 결과

모델	R^2	MSE	RMSE (억)	비고
선형 회귀 (Baseline)	0.756	10.86	3.30	타자보다 훨씬 높은 설명력
랜덤 포레스트	0.570	19.11	4.37	선형회귀보다 낮음


모델	R ²	MSE	RMSE (억)	비고
XGBoost	측정 예정	—	—	향후 실험


해석: 투수 선형회귀 R² 0.756으로 타자보다 훨씬 높다. 투수는 ERA·이닝·WAR 등 핵심 성적 지표가 연봉을 잘 설명하는 반면, 타자는 비성적 요인의 영향이 더 크기 때문으로 분석된다.

랜덤포레스트 < 선형회귀 이유: FA 투수 데이터 43명으로는 트리 계열 모델이 패턴을 충분히 학습하기 어려운 소규모 데이터다. 단순한 선형 관계가 더 적합하게 작동한 케이스로, 소규모 데이터에서는 복잡한 모델이 항상 좋지 않음을 보여준다.

6.4 예측값 vs 실제값 비교

```
import matplotlib.pyplot as plt import koreanize_matplotlib # 실제값 vs 예측값 산점도
fig, axes = plt.subplots(1, 2, figsize=(12, 5)) for ax, (title, y_t, y_p) in zip(axes, [ ('타자 모델', y_test_hitter, pred_hitter), ('투수 모델', y_test_pitcher, pred_pitcher), ]): ax.scatter(y_t, y_p, alpha=0.7, color='steelblue', s=60) lim = [0, max(y_t.max(), y_p.max())+2] ax.plot(lim, lim, 'r--', linewidth=1.5, label='y=x (완벽 예측선)') ax.set_xlabel('실제 연봉 (억 원)') ax.set_ylabel('예측 연봉 (억 원)') ax.set_title(f'{title} - 실제값 vs 예측값') ax.legend() plt.tight_layout(); plt.show() # 선수별 비교 막대 그래프
idx = range(len(y_test_hitter)); width = 0.35
fig, ax = plt.subplots(figsize=(14, 5)) ax.bar([i-width/2 for i in idx], y_test_hitter, width, label='실제 연봉', color='#2196F3', alpha=0.8) ax.bar([i+width/2 for i in idx], pred_hitter, width, label='예측 연봉', color='#FF9800', alpha=0.8) ax.set_title('선수별 실제 vs 예측 연봉 비교'); ax.legend() plt.tight_layout(); plt.show()
```





7. Feature Importance 분석

7.1 개요

랜덤 포레스트의 `feature_importances_` 속성을 이용해 각 피처가 연봉 예측에 기여하는 상대적 중요도를 산출하였다. 중요도 값은 0~1이며 전체 합이 1이다. 이를 통해 '어떤 성적이 연봉을 결정하는가'를 정량적으로 분석할 수 있다.

```
importance_df = pd.DataFrame({ 'feature': X_train.columns,
                              'importance': rf_model.feature_importances_, }).sort_values('importance',
ascending=False) # 시각화 importance_df.head(15).plot(kind='barh',
x='feature', y='importance', figsize=(8, 6), color='steelblue', legend=False)
plt.gca().invert_yaxis() plt.xlabel('중요도 (Importance)') plt.title('Feature
Importance - 상위 15개') plt.tight_layout(); plt.show()
```

7.2 타자 Feature Importance — 상위 7개


순위	피처명	중요도(추정)	한글 의미	인사이트
1위	war_3yr_sum	0.18+	WAR 3년 합계	팀에 기여한 총량이 연봉의 핵심 결정 요소. 에이스·주전 여부 판별
2위	run_3yr_avg	0.09+	득점 3년 평균	단순 안타보다 '실제 점수 기여'가 구단이 보는 가치
3위	double_3yr_avg	0.08+	2루타 3년 평균	홈런보다 안정적인 장타력. 타선 흐름 연결 능력
4위	ops_last_year	0.07+	직전 시즌 OPS	가장 최근 상태가 계약에 반영됨. FA 협상 직전 해 성적이 중요
5위	woba_3yr_avg	0.07+	wOBA 3년 평균	타격 결과별 가중 종합 지

순위	피처명	중요도(추정)	한글 의미	인사이트
				표. 리그 평균 대비 공격력
6위	war_last_year	0.06+	직전 시즌 WAR	최근 경쟁력 신호. 장기 부상 여부 반영
7위	age_at_fa	0.05+	FA 당시 나이	나이 많을수록 계약 연한·금액 감소 경향

 **[캡처 10] model_train_v2.ipynb** — 타자 Feature Importance 수평 막대그래프 (상위 10~15개)

7.3 투수 Feature Importance — 상위 5개

순위	피처명	중요도(추정)	인사이트	주의사항
1위	fa_year	0.25+	연봉 인플레이션 반영. 연도가 최신일수록 높은 계약금	△ 순수 성적 지표 아님. 시장 인플레이션 흡수
2위	innings_3yr_avg	0.18+	소화 이닝 많을수록 = 선발 풀타임 에이스. 팀 가치 높음	선발/불펜 구분에 가장 직접적
3위	hold_3yr_avg	0.12+	셋업맨의 핵심 실적. 불펜 안정성 지표	SU 포지션 중요도 반영
4위	era_3yr_avg	0.10+	방어율. 가장 직관적 투수 성적 지표	낮을수록 우수 (역관계)
5위	war_3yr_sum	0.09+	포지션 내 상대적 기여도	타자 1위와 동일 지표. 팀 기여도 보편성



8. Streamlit 서비스 구현 (StoveLens AI)

8.1 서비스 설계 원칙

- 사용자 대상: 야구 팬, 구단 관계자, 스포츠 기자 등 통계 전문가가 아닌 일반인
- 전문 통계 용어 노출 금지: R^2 , RMSE, XGBoost, Feature Importance 등은 사용자 화면에 절대 표시하지 않음
 - 대신 '이 선수의 연봉을 결정한 핵심 요소', '리그 상위 N%', 'AI 예측 연봉' 등 직관적 표현 사용
- 기술 지표는 [상세 보기 ▼] 토글 안에만 표시 (교수님 발표·보고서용)
- 모바일·와이드 스크린 모두 가독성 확보. Streamlit dark theme 적용


8.2 전체 화면 흐름 (2가지 모드 자동 분기)

단계	동작	기술 구현
① 메인화면	선수 이름 텍스트 입력 + 팀 필터 드롭다운 (선택)	st.text_input / st.selectbox
② 검색	fa_contracts_v3.csv에서 선수명 조회	pandas 직접 필터링
③ 모드 분기	계약 기록 있음 → 모드 A 계약 기록 없음 → 모드 B	if/else 분기 + st.session_state 페이지 라우터
모드 A	FA 완료 선수: 예측 vs 실제 비교	hitter/pitcher_model.pkl 로드 → 예측값 계산
모드 B	미래 FA 예정 선수: 예측 + 구단별 제시가	future_fa_candidates.csv 매칭 + 구단 보정계수 적용

8.3 모드 A — FA 완료 선수 화면

UI 구성요소	표시 내용	기술 구현
선수 프로필 카드	이름·소속팀·포지션·FA 연도·선수 사진	네이버 스포츠 API 선수 이미지 URL 추출 → st.markdown(img 태그, unsafe_allow_html=True)
연봉 비교 가로 바	예측 연봉 vs 실제 계약 연봉 시각화 "실제가 예측보다 N억 높습니다. 고평가" 코멘트	plotly go.Bar + 텍스트 레이블


UI 구성요소	표시 내용	기술 구현
핵심 요소 Top 3	연봉 예측에 기여한 주요 스탯 3개 (마우스 오버 시 툴팁)	Feature Importance 상위 피쳐 + 실제 수치 출력
최근 3년 스탯 요약	연도별 타율/OPS/WAR 또는 ERA/이닝/WAR	HTML 테이블 (다크테마 글씨 안보이는 문제 해결)
[상세 보기 ▼] 토크	전체 커리어 스탯·WAR추이·레이더 차트·AI 종합평가	st.expander + plotly Scatterpolar 레이더 차트



8.4 모드 B — 미래 FA 예정 선수 화면/

UI 구성요소	표시 내용
AI 예상 연봉	'₩ 약 N억 원 / 년' 형태 대형 표시 (실제치 없으므로 비교 없음)
핵심 요소 Top 3	연봉 결정 주요 스탯 + 리그 내 백분위
구단별 예상 제시가	10개 구단 × 제시가 범위 막대 + 잔류 가능성 레이블('잔류 가능성 높음')

UI 구성요소	표시 내용
최근 3년 스탯 요약	HTML 테이블로 핵심 지표 연도별 정리
[상세 보기 ▼] 토글	전체 스탯·추이 차트·레이더·AI 종합평가



8.5 구단별 적정 제시가 산출 방법 (2차 보정)

1차 모델 예측값에 구단별 보정계수를 곱하여 각 구단의 적정 제시가를 산출한다. **공식: 구단별 제시가 = 예측 연봉 × 보정계수**

구단	보정계수	반영 근거	원나우
LG 트윈스	× 1.08	26시즌 1위, 대형 예산, 연속 우승 의지	Yes
KIA 타이거즈	× 1.06	전통 강호, 최대 팬 규모	Yes
한화 이글스	× 1.05	공격적 FA 시장 참여 최근 기조	Yes
두산 베어스	× 1.04	서울 연고, 우수 팬덤	가능
삼성 라이온즈	× 1.00	리그 평균 기준점	중립
SSG 랜더스	× 0.97	재정 구조조정 가능성	No
KT 위즈	× 0.95	중소 예산 구단	No
NC 다이노스	× 0.94	최근 성적 부진, 재건 국면	No

구단	보정계수	반영 근거	원나우
롯데 자이언츠	× 0.92	FA 장기계약 보수적	No
키움 히어로즈	× 0.85	육성 중심, FA 지양 기조	No

9. 트러블슈팅 (Troubleshooting)

개발 과정에서 발생한 주요 문제와 해결 방법을 기록한다.

9.1 [데이터] pitcherInning 문자열 오류

항목	내용
문제	pitcherInning 컬럼이 '184 1/3' 형식 문자열로 수집됨 → .mean() 호출 시 TypeError
오류 메시지	TypeError: Cannot perform reduction 'mean' with string dtype
원인	네이버 API가 이닝을 '정수 분수' 혼합 문자열로 반환. float 변환 없이 바로 통계 연산 시도
해결	_parse_inning() 커스텀 파싱 함수 작성 → '184 1/3' → 184.333 변환. stat_df 로드 직후 apply()
교훈	외부 API 데이터는 dtype 반드시 확인. pd.to_numeric(errors='coerce') 보다 도메인 특화 파싱이 필요한 케이스 존재

9.2 [데이터 누수] v1 모델 $R^2 \approx 1.00$

항목	내용
문제	초기 v1 모델의 R^2 값이 0.99에 가깝게 나옴. 비정상적으로 높음
원인	total_contract_amount(총액)과 contract_years(계약기간)가 피처에 포함됨. 연봉 = 총액 ÷ 기간이므로 모델이 답을 역산
발견 경위	Feature Importance 확인 시 total_contract_amount가 압도적 1위 → 의심 → 제거 실험 시 R^2 급락으로 확인
해결	drop_cols 리스트에 total_contract_amount, contract_years 추가 → 완전 제외. 타자 $R^2=0.388$, 투수 $R^2=0.756$ 으로 현실화
교훈	타깃과 직접 연산 관계인 파생 변수는 즉시 제거. Feature Importance 1위 피처 중 '이게 왜 중요하지?'를 항상 의심

9.3 [UI] 다크 테마에서 st.dataframe 글씨 안 보임

항목	내용
문제	Streamlit 앱에서 상세 스탯 테이블 영역이 '빈 박스'처럼 보임. 실제로는 흰 배경에 흰 글씨
원인	Streamlit 커스텀 다크 테마(#0f0f1a 배경)에서 st.dataframe()의 텍스트 색상이 흰색으로 렌더링되지 않음
해결	_html_table() 함수로 직접 HTML <table> 태그 생성 → st.markdown(html, unsafe_allow_html=True). 셀 색상·글자색 직접 지정
코드	th_style = 'color:#aacdff; background:#1a1a2e; ...' td_style = 'color:#f0f0f0; background:#0f0f1a; ...'
교훈	Streamlit 기본 컴포넌트는 테마에 따라 렌더링이 다름. 다크 테마 + 정밀 스타일 제어가 필요하면 HTML 직접 사용

9.4 [UI] 선수 프로필 사진 미로딩

항목	내용
문제	선수 이름으로 프로필 사진을 가져오려 했으나 이미지가 로드되지 않음
원인	초기에 잘못된 API 엔드포인트 사용. 네이버 스포츠 KBO 이미지 URL 구조 파악 미흡
해결	2026/2025/2024/2023년 시즌 데이터 API를 순차 탐색하여 선수 playerKey 획득 → 이미지 URL 조합. st.image() 대신 HTML img 태그로 직접 렌더링 (스타일 제어 편의)
추가 조치	requests 타임아웃 설정, 이미지 로드 실패 시 기본 이미지(野球 실루엣) fallback 처리
교훈	외부 이미지 API는 엔드포인트 구조와 응답 형식을 사전에 충분히 파악해야 함. Fallback 항상 설계

9.5 [모델] 투수 FA 데이터 부족으로 RF 성능 저하

항목	내용
문제	투수 RandomForest $R^2 = 0.570$ < 선형회귀 $R^2 = 0.756$. 양상불이 더 나쁨
원인	학습 데이터 43명 → 테스트 9명. 트리 계열은 데이터가 충분해야 일반화 가능.

항목	내용
	소규모에서는 오히려 단순 모델이 우수
해결	투수 최종 모델로 선형회귀 채택 (설명력+해석력 모두 우수). 향후 데이터 확장 시 재실험
교훈	데이터 적을수록 복잡한 모델이 항상 좋은 건 아님. 과적합 vs 편향 트레이드 오프 고려

9.6 [Streamlit] 미래 FA 선수 검색 결과 없음

항목	내용
문제	2027~2030년 FA 예정 선수를 검색해도 '선수를 찾을 수 없습니다' 출력
원인	미래 FA 후보 데이터셋(future_fa_candidates.csv) 미구축 상태였음. 데뷔 연도 기반 FA 예정 연도 계산 로직 미구현
해결	고졸(FA=데뷔연+10), 대졸(데뷔연+9) 규칙으로 2016~2021년 데뷔 선수 중 FA 예정자 추출. 현재 소속팀·포지션·player_type 포함 CSV 생성
교훈	서비스의 핵심 기능에 필요한 데이터는 사전에 완전히 확보. MVP 버전이라도 동작 가능한 최소 데이터셋 필요

10. 한계점 및 개선 방향

10.1 현재 모델의 한계점

한계점	상세 내용	영향
소규모 학습 데이터	타자 80명 / 투수 43명. 투수 테스트셋 9명으로 성능 신뢰도 낮음. KBO FA는 연간 5~15명 수준이라 데이터 축적 속도가 느림	과적합 위험, 통계적 불안정
비성적 요인 미반영	스타성(팬 인기도)·에이전트 역량·부상 내역·구단 감독 선호도 등 수치화 어려운 요인들이 실제 연봉에 큰 영향	타자 R^2 0.39 한계
fa_year 의존성	투수 Feature Importance 1위가 fa_year → 연봉 인플레이션 반영. 순수 성적 예측력이 아님	미래 예측 시 fa_year 설정 불명확
포지션별 세분화 부재	포수·유격수 등 희소 포지션은 같은 성적에도 프리미엄 존재하나 현재 모델 미반영	포지션 가치 왜곡
구단별 보정 주관성	보정계수를 데이터 기반이 아닌 수동 설계 → 실제 구단 예산·필요도와 오차 가능	2차 보정의 신뢰도 한계

10.2 향후 개선 방향

개선 방향	구체적 방법	기대 효과
스타성 변수 추가	MVP·골든글러브·올스타·국가대표·포스트 시즌 경험 수치화 ($\text{star_score} = \text{MVP} \times 5 + \text{GG} \times 3 + \text{국가대표} \times 2 + \text{올스타} \times 1$) → hitter_training_v5.csv 생성	타자 R^2 0.39 → 0.55+ 예상
투수 역할 피쳐 추가	SP/SU/CL 분류 후 원핫인코딩 → XGBoost 입력 (pitcher_training_v5.csv 생성 예정)	역할별 예측 정밀도 향상
학습 데이터 확장	2010~2014년 KBO 데이터 추가 수집 해외 진출 후 복귀 선수 데이터 보완 → 타자 100명+, 투수 60명+ 목표	모델 일반화 성능 향상
앙상블 고도화	XGBoost + LightGBM + RF 스택킹 (Stacking) 앙상블 적용	단일 모델 한계 극복

개선 방향	구체적 방법	기대 효과
구단 보정계수 데이터화	구단별 최근 3년 FA 지출 내역 분석으로 보정계수 자동 산출	주관성 제거
fa_year 처리 개선	연봉 인플레이션을 CPI 유사 지수로 명시적 보정 → fa_year 의존도 감소	해석 가능성 향상

부록. 캡처·그래프 삽입 체크리스트

본문 내 동일 번호(📷 [캡처 N]) 위치에 아래 내용을 순서대로 삽입하세요.

번호	본문 위치 (섹션)	삽입할 내용	생성 명령어	완료
 A	1.4 추진방법 3)	DATA IMPORTING→USER INSIGHT 5단계 흐름도	도형 직접 작성	☐
 1	2.3 선수 스탯 수집	원시 데이터 CSV head/shape/dtypes 출력	Jupyter df.head()	☐
 2	3.3 결측치 처리	결측치 처리 전/후 isnull().sum() 출력	df.isnull().sum()	☐
 3	3.4 학습 데이터셋	hitter/pitcher_training_v4 describe()	df.describe()	☐
 4	4.1 연봉 분포	타자/투수 연봉 분포 히스토그램	sns.histplot()	☐
 5	4.2 연도별 추이	연도별 평균 연봉 추이 선그래프	sns.lineplot()	☐
 6	4.3 상관관계	피처-연봉 상관관계 히트맵 (타자/투수)	sns.heatmap()	☐
 7	5.3 모델 학습	R ² /RMSE/MAE 출력 결과 화면	노트북 셀 실행 출력	☐
 8	6.4 실제vs예측	실제값 vs 예측값 산점도 (타자/투수)	plt.scatter(y_test, pred)	☐
 9	6.4 선수별 비교	선수별 실제 vs 예측 막대 그래프	plt.bar (비교)	☐

번호	본문 위치 (섹션)	삽입할 내용	생성 명령어	완료
 10	7.2 타자 FI	타자 Feature Importance 수평 막대그래프	importance.plot('barh')	☐
 11	7.3 투수 FI	투수 Feature Importance 수평 막대그래프	동일	☐
 12	8.3 모드 A 화면	FA 완료 선수 검색 결과 스크린샷	Streamlit 앱 캡처	☐
 13	8.4 모드 B 화면	미래 FA 예정 선수 + 구단별 제시가	Streamlit 앱 캡처	☐

— 끝 —